

UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Previsão de consumo nos estados do Brasil

Julia Leite da Silva

MONOGRAFIA FINAL

MAC 499 — TRABALHO DE
FORMATURA SUPERVISIONADO

Supervisor: Prof. Dr. Marcelo Finger

São Paulo
2022

*O conteúdo deste trabalho é publicado sob a licença CC BY 4.0
(Creative Commons Attribution 4.0 International License)*

Dedico este trabalho a minha família, meu pai e minha mãe que têm iluminado meu dia e me dado força, alegria e paz. Acima de tudo, dedico a Deus, quem me presentou com capacidade, com uma família maravilhosa e que foi adicionando pessoas no meu caminho para me apoiar e me ajudar em cada passo da jornada.

Agradecimentos

Fight with determination, embrace life and live it with passion. Lose your battles with class and dare to win because the world belongs to those who dare to live. Life is worth too much to be insignificant.

— Charles Chaplin

Queria agradecer, antes de tudo, a Deus por tudo que Ele tem me dado. Uma vez minha mãe me disse que Deus abençoa o trabalho das nossas mãos, que várias vezes onde ela pensou que não daria certo ou não daria conta, ela pedia ajuda e, no final, tudo se endireitava. Ela me disse também que Deus colocava pessoas na vida dela que a ajudavam e orientavam a encontrar um caminho. Fico muito grata de enxergar isso acontecendo na minha vida também.

Agradeço aos meus pais, que têm sido minha força, alegria e lar. Agradeços aos meus amigos e amigas, por colorir meus dias e encher meu rosto de sorrisos.

Quero também agradecer ao Marcelo Finger, meu orientador obrigada para o Felipe, que me surpreendeu com a parceria e a nessa jornada. Muito ajuda. Agradecer também ao Gabriel, pelo apoio para escrever esse trabalho.

Resumo

Julia Leite da Silva. **Previsão de consumo nos estados do Brasil**. Monografia (Bacharelado). Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, 2022.

[illegible]

Palavras-chave: Palavra-chave1. Palavra-chave2. Palavra-chave3.

Abstract

Julia Leite da Silva. . Capstone Project Report (Bachelor). Institute of Mathematics and Statistics, University of São Paulo, São Paulo, 2022.

[illegible]

Keywords: Keyword1. Keyword2. Keyword3.

Lista de Abreviaturas

MLP	Perceptron Multi-Camadas (<i>Multilayer perceptron</i>)
LSTM	(<i>Long Short Term Memory</i>)
RMSE	Raíz Média de erros Quadrados (<i>Root Mean Squared Error</i>)
MAPE	Erro Percentual Absoluto Médio (<i>Mean Absolute Percentage Error</i>)

Lista de Símbolos

ω	Frequência angular
ψ	Função de análise <i>wavelet</i>
Ψ	Transformada de Fourier de ψ

Lista de figuras

1.1	Relação entre inteligência artificial, aprendizado de máquina e <i>deep learning</i> PATTERSON e GIBSON, s.d.	4
1.2	Exemplo de um modelo simples de regressão linear HYNDMAN e ATHANASOPOULOS, 2021	6

Lista de tabelas

Lista de programas

Sumário

Introdução	1
1 Fundamentação teórica	3
1.1 Aprendizado de máquina	3
1.2 Problema	4
1.3 Regressão linear	5
1.4 Redes neurais	6
1.4.1 Redes neurais multi-layer perceptrons	6
1.4.2 Redes Neurais Recorrentes	6
1.4.3 Função de ativação	7
1.4.4 Normalização	7
2 Metodologia	9
3 Experimentos	11
3.1 regressao linear	11
4 Resultados	13
5 Conclusão	15
 Referências	 17

Introdução

O que prédios, pontes, hidrelétricas e aeroportos têm em comum? Todos são frutos da indústria da construção civil, um importante componente do investimento brasileiro e, consequentemente, uma das grandes engrenagens responsáveis por movimentar a atividade econômica no Brasil. Em 2021, por exemplo, o Produto Interno Bruto (PIB) desse setor registrou alta de 9,7%, enquanto o PIB do Brasil cresceu 4,6%, assim, o setor da construção figura como importante impulsionador da economia do país. [VASCONCELOS, 2022](#) O cimento, nesse contexto, por ser um ingrediente central da argamassa e do concreto, caracteriza-se como um dos principais insumos da indústria.

Motivação

Contudo, a falta de um modo bem fundamentado para prever a demanda de cimento é uma dor entre as empresas cimenteiras, uma vez que a construção de uma fábrica é custosa e demorada, além disso, aumentar a capacidade de produção de uma fábrica também é um processo custoso.

Dessa forma, um modelo que permitisse prever a demanda a nível de estados do Brasil poderia auxiliar gestores a tomar melhores decisões e a estruturar a estratégia de forma mais embasada, de modo a reduzir os riscos do setor. Além disso, poder-se-ia apoiar órgãos governamentais a direcionar ações para mitigar o impacto ambiental da fabricação desse produto.

Objetivos

Este trabalho, então, propõe-se a aplicar modelos de aprendizado de máquina para determinar qual é mais eficiente para prever a demanda por cimento nos estados do Brasil. Os modelos avaliados são: regressão linear, redes neurais *multi-layer perceptron* (MLP) e redes neurais recorrentes.

Capítulo 1

Fundamentação teórica

1.1 Aprendizado de máquina

Atualmente, inteligência artificial (IA) permeia diversos momentos do cotidiano. É o caso da empresa norte-americana de *streaming* Netflix, que utiliza um conjunto de técnicas de IA para recomendar conteúdo personalizado aos usuários da plataforma de acordo com os interesses particulares de cada um. Dessa forma, proporciona uma experiência única a cada indivíduo que acessa a plataforma com o objetivo de aumentar a satisfação a longo prazo e, consequentemente, garantir a retenção dos membros, uma vez que a plataforma é monetizada com assinaturas mensais.

Além disso, não há um modelo ou algoritmo único utilizado para todas as recomendações de conteúdo. Essa tarefa é dividida em subtarefas realizadas por diferentes modelos de acordo com a atividade a ser realizada e os dados disponíveis. Por exemplo, a sub tarefa de decidir qual vídeo será exibido para cada usuário ao logar no perfil da plataforma é executada por um modelo diferente do que o que elenca os vídeos já assistidos que o membro pode continuar a ver. [STECK et al., 2021](#)

Mas a final, o que é inteligência artificial (IA)? O termo "inteligência artificial", *artificial intelligence* em inglês, foi elaborado por John McCarthy e utilizado oficialmente pela primeira vez em 1956 no seminário de Dartmouth, um *workshop* sobre essa área que reuniu os maiores estudiosos do ramo durante dois meses. [RUSSELL e NORVIG, s.d.](#) Esse termo apresenta várias definições, de acordo com o pioneiro Arthur Samuel, pode ser definida como o campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados. [PATTERSON e GIBSON, s.d.](#)

Aprendizado de máquina, por sua vez, do inglês *machine learning*, são sistemas de IA capazes de adquirir seu próprio conhecimento por meio da extração de padrões dos dados brutos. Configura-se, portanto, como uma sub-área de inteligência artificial. [GOODFELLOW et al., 2016](#). O aprendizado profundo, ou *deep learning*, é uma categoria específica de *machine learning* que compreende modelos de redes neurais com várias camadas de neurônios. [ZHANG et al., 2021](#)

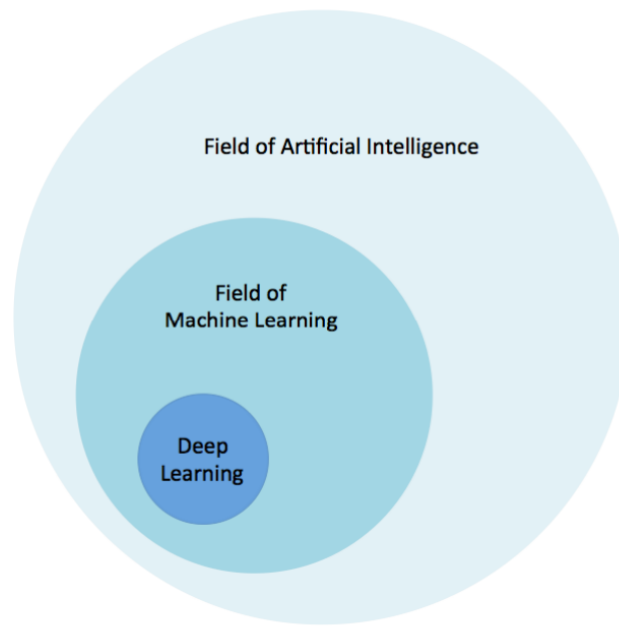


Figura 1.1: Relação entre inteligência artificial, aprendizado de máquina e deep learning *PATTERSON e GIBSON, s.d.*

1.2 Problema

As tarefas de *machine learning* são descritas de acordo com o processamento que o modelo deve realizar a partir de um exemplo de entrada (*input*), em geral, descrito com um vetor $x \in \mathbb{R}^n$, $x = \{x_1, x_2, \dots, x_n\}$. Por exemplo, neste trabalho um exemplo de *input* seriam os dados de março de 2011 do estado de São Paulo, cada entrada x_i , então, corresponde à medição de um dos indicadores econômicos desse estado e mês, logo x_1 pode representar o PIB estadual, x_2 o PIB *per capita* e assim sucessivamente.

Nas tarefas de classificação, o modelo deve prever a qual das k categorias disponíveis um *input* pertence. O algoritmo então cria uma função $f : \mathbb{R}^n \rightarrow 1, \dots, k$, quando $f(x) = y$, o vetor de entrada x foi recebido a categoria y . Um exemplo de tarefa de classificação seria determinar se o consumo de cimento em um estado em um mês específico representa um aumento, queda ou estabilidade em relação ao mês anterior. Neste trabalho, contudo, não se utiliza esse tipo de tarefa. *GOODFELLOW et al., 2016*

Outra categoria de tarefas são as de regressão, aonde o objetivo é, a partir do *input* x , prever um valor numérico. A função criada pelo modelo, então, é $f : \mathbb{R}^n \rightarrow \mathbb{R}$. O problema abordado neste trabalho, então, configura-se como problema de regressão, uma vez que o objetivo é prever o valor do consumo de cimento em um estado e mês específicos a partir dos dados de entrada.

Os problemas de aprendizado de máquina também podem ser divididos entre aprendizado não-supervisionado e supervisionado. No primeiro, o modelo recebe um *dataset* não rotulado e então aprende propriedades da estrutura do *dataset*, pode, então, performar tarefas como a clusterização, que consiste em dividir o conjunto de dados em *clusters*

com exemplos similares. No último, por sua vez, os dados de entrada estão associados a rótulos, resultados conhecidos, chamados de *labels* ou *target* em inglês. Neste trabalho, a utiliza-se aprendizado supervisionado, uma vez que o real consumo de cimento no mês é conhecido. [GOODFELLOW et al., 2016](#)

1.3 Regressão linear

A regressão linear é um modelo de aprendizado de máquina que assume um relacionamento linear entre a variável que será prevista (*target*) e os dados de entrada. Dessa forma, o objetivo é obter uma função linear que receba um vetor $x \in \mathbb{R}^n$, $x = \{x_1, x_2, \dots, x_n\}$ como entrada e devolva a previsão de um escalar $y \in \mathbb{R}$. [GOODFELLOW et al., 2016](#) Seja \hat{y} o valor previsto pelo modelo para \hat{y} , então:

$$\hat{y} = w^T x + b \quad (1.1)$$

aonde $w \in \mathbb{R}^n$, $w = \{w_1, w_2, \dots, w_n\}$ é um vetor de parâmetros. Em particular, w corresponde a um conjunto de pesos que determina como cada variável afeta a previsão. Então, se x_i for associado a um peso w_i positivo, aumentar o valor de x_i resulta em um aumento na previsão \hat{y} , se w_i for negativo, por outro lado, um aumento de x_i resulta em diminuição de \hat{y} . Se w_i for igual a 0, por sua vez, a variável x_i não influencia no valor previsto.

A constante b , do inglês *bias*, é um parâmetro para mensurar viés, já que o *output* da função é b na ausência de uma entrada. Dessa forma, a equação 1.1 pode ser escrita da seguinte forma:

$$\hat{y} = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b \quad (1.2)$$

Na ilustração abaixo, um exemplo de um modelo de regressão linear com apenas uma variável:




Figura 1.2: Exemplo de um modelo simples de regressão linear *HYNDMAN e ATHANASOPOULOS, 2021*

Nessa imagem, as observações estão representadas nos pontos pretos, enquanto a linha em laranja corresponde à previsão realizada pelo modelo. Observa-se que o modelo não prevê com total exatidão os dados observados, há um erro associado a cada previsão, como o destacado em verde na ilustração.

Dessa forma, cada observação y_i possui um erro ε_i associado e pode ser descrita por $y_i = w^T x_i + b + \varepsilon_i$. O vetor de pesos w , então, é escolhido de modo a minimizar os erros em cada previsão.

Por se tratar de um modelo mais simples, é utilizada neste trabalho como base para comparar o desempenho de outros modelos mais robustos.

1.4 Redes neurais

1.4.1 Redes neurais multi-layer perceptrons

Redes neurais são modelos de *machine learning* inspiradas no cérebro humano aonde o aprendizado ocorre ao se agregarem neurônios matemáticos que estabelecem conexões de acordo com o treinamento fornecido. Neste trabalho, aplicaram-se redes *multilayer perceptrons* (MLPs), ou seja, que apresentam múltiplas camadas de neurônios e *feedforward*, onde a saída de uma camada de neurônios é utilizada como entrada para a camada seguinte, sem utilizar retropropagação.

1.4.2 Redes Neurais Recorrentes

Já as redes neurais recorrentes são projetadas para reconhecer padrões nos dados, uma vez que levam tempo e sequência em consideração. Assim, nessas redes, a decisão tomada na etapa anterior influencia a etapa seguinte por conta dos *loops de feedback*, então o presente e o passado recente se combinam para determinar a previsão. Neste trabalho,

foram testadas as redes Long Short Term Memory (LSTM), redes Gated Recurrent Unit (GRU) e Bidirecionais.

GRU

LSTM

1.4.3 Função de ativação

1.4.4 Normalização

Capítulo 2

Metodologia

Os modelos recebem como entrada dados econômicos obtidos do Instituto Brasileiro de Geografia e Estatística (IBGE), Fundação Getúlio Vargas (FGV), Instituto de Pesquisa Econômica Aplicada, entre outros. Sobre crescimento econômico, foram utilizados: PIB do estado, PIB per capita, população, PIB da construção civil e desemprego. Já para política fiscal, utilizou-se: Necessidade de Financiamento do Setor Público (NFSP) e Estoque da Dívida Pública. Para mensurar a inflação foram utilizados Índice de Preços ao Consumidor Aplicado (IPCA), Índice Nacional de Custo da Construção (INCC) e Índice Geral de Preço (IGP). O Índice de Desenvolvimento Humano (IDH) foi utilizado como indicador social. Finalmente, a produção de cimento e o preço do saco de 50kg, da tonelada e do quilograma de cimento foram utilizados como indicadores da construção civil.

A partir da análise exploratória dos dados de entrada, optou-se por utilizar dados de 2003 até 2019, com granularidade mensal, para realizar o estudo. Se os indicadores apresentavam granularidade anual, calculou-se a divisão da medição de cada ano por 12 meses para obter a média mensal. Além disso, caso o dado estivesse disponível apenas a nível de Brasil, ao invés de por estado, o valor da medição da União foi utilizado para todos os estados.

A estratégia utilizada para lidar com dados faltantes nas variáveis de entrada foi repetir o valor da ocorrência anterior ou marcar a entrada com um valor não presente no intervalo de dados, a exemplo de marcar -1"como valor da produção mensal de cimento em um determinado mês em um estado específico.

Finalmente, os dados utilizados como entrada foram deslocados um mês à frente ou um ano, no caso dos indicadores anuais, em relação aos dados de consumo. Dessa forma, os dados correspondentes a, por exemplo, fevereiro de 2004 estão relacionados ao consumo de cimento em março de 2004, com o objetivo de propor um cenário mais pertinente, uma vez que o objetivo do projeto é prever a demanda por cimento no mês seguinte em um estado a partir dos dados do mês atual e, eventualmente, dos anteriores.

Capítulo 3

Experimentos

3.1 regressao linear

Capítulo 4

Resultados

blafgdf .

Capítulo 5

Conclusão

ahahahahahh

Referências

- [GOODFELLOW *et al.* 2016] Ian GOODFELLOW, Yoshua BENGIO e Aaron COURVILLE. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016 (citado nas pgs. 3–5).
- [HYNDMAN e ATHANASOPOULOS 2021] Rob J HYNDMAN e George ATHANASOPOULOS. *Forecasting: principles and practice*. 3^a ed. OTexts.com/fpp3. Accessed on 17 December 2022. OTexts, 2021 (citado na pg. 6).
- [PATTERSON e GIBSON s.d.] Josh PATTERSON e Adam GIBSON. *Deep Learning: A practitioner’s approach* (citado nas pgs. 3, 4).
- [RUSSELL e NORVIG s.d.] Stuart J. RUSSELL e Peter NORVIG. *Artificial Intelligence: A Modern Approach, third edition* (citado na pg. 3).
- [STECK *et al.* 2021] Harald STECK *et al.* “Deep learning for recommender systems: a netflix case study”. Em: *AI Magazine* 42.3 (nov. de 2021), pgs. 7–18. DOI: [10.1609/aimag.v42i3.18140](https://doi.org/10.1609/aimag.v42i3.18140). URL: <https://ojs.aaai.org/index.php/aimagazine/article/view/18140> (citado na pg. 3).
- [VASCONCELOS 2022] Ieda VASCONCELOS. *Informativo Econômico PIB*. 2022. URL: <https://cbic.org.br/wp-content/uploads/2022/03/informativo-economico-pib-04-marco-2022.pdf> (citado na pg. 1).
- [ZHANG *et al.* 2021] Aston ZHANG, Zachary C. LIPTON, Mu LI e Alexander J. SMOLA. “Dive into deep learning”. Em: *arXiv preprint arXiv:2106.11342* (2021) (citado na pg. 3).